

# Predicting Ratings with Neighborhood-Based Methods

Florian Orpelière

June 27, 2017

## 1 Formules de bases

Posons les éléments suivants :

- La moyenne des notes d'un utilisateur  $u$  est  $\mu_u$ .  $I_u$  représente l'ensemble des items que l'utilisateur  $u$  a noté :

$$\mu_u = \frac{\sum_{k \in I_u} r_{uk}}{|I_u|}$$

- La similarité de Pearson (général):

$$Sim(x, y) = Pearson(x, y) = \frac{\sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Où  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$  est la moyenne des  $x$ .

On pourrait en utiliser d'autres. Celle-ci a la propriété d'avoir des valeurs comprises entre -1 et 1.

$$s_{uj} = r_{uj} - \mu_u$$

Où  $r_{uj}$  est la note d'un utilisateur  $u$  sur l'item  $j$ .

## 2 Neighborhood Models basé sur les utilisateurs

On commence par calculé la similarité entre deux utilisateurs  $u$  et  $v$ .

$$\begin{aligned}
 & Sim(u, v) \\
 &= Pearson(u, v) = \frac{\sum_{k \in I_u \cap I_v} (r_{uk} - \mu_u) \cdot (r_{vk} - \mu_v)}{\sqrt{\sum_{k \in I_u \cap I_v} (r_{uk} - \mu_u)^2} \sqrt{\sum_{k \in I_u \cap I_v} (r_{vk} - \mu_v)^2}} \\
 &= \frac{\sum_{k \in I_u \cap I_v} s_{uk} \cdot s_{vk}}{\sqrt{\sum_{k \in I_u \cap I_v} s_{uk}^2} \sqrt{\sum_{k \in I_u \cap I_v} s_{vk}^2}}
 \end{aligned}$$

Avec  $\sum_{k \in I_u \cap I_v} (r_{uk} - \mu_u) \cdot (r_{vk} - \mu_v)$  qui est le produit scalaire des vecteurs  $r_u$  et  $r_v$  minoré par leur moyenne  $\mu_u$  et  $\mu_v$  respectivement. Donc le produit scalaire des notes d'un utilisateurs  $u$  et  $v$  centrées sur la moyenne.

Puis,  $\sqrt{\sum_{k \in I_u \cap I_v} (r_{uk} - \mu_u)^2}$  et  $\sqrt{\sum_{k \in I_u \cap I_v} (r_{vk} - \mu_v)^2}$  qui est la norme des vecteurs  $r_u$  et  $r_v$  minoré par leur moyenne  $\mu_u$  et  $\mu_v$ .

Nous pouvons prédire la note d'un utilisateur  $u$  sur l'item  $j$  :

$$r_{uj} = \mu_u + \frac{\sum_{v \in P_u(j)} Sim(u, v) \cdot s_{vj}}{\sum_{v \in P_u(j)} |Sim(u, v)|}$$